

От одного генома к тридцати

Проверка классификатора делеций PAIR-SV и выбор порога с гарантией

Статья 1 — готова к подаче

Статья 2 — результаты получены, пишется текст

Отчёт о выполненной работе · сентябрь 2026

ЗАДАЧА

Отсеять ложные находки детектора

Прочтения ДНК человека → Manta — детектор делеций → Кандидаты на делецию → **PAIR-SV — перепроверка** → Принять или отсеять

88%

находок Manta — настоящие делеции (в среднем по 30 людям)

12%

— ложные срабатывания. Их надо найти, не потеряв настоящие

Чего PAIR-SV не делает

Не ищет делеции заново. Что пропустил детектор, остаётся пропущенным: на эталонном геноме HG002 сама Manta нашла 42,7% известных делеций.

Пять версий классификатора

	Изображение прочтений	Последова-тельность ДНК	Прочтения человека	17 числовых признаков
M0 самая простая	●	○	○	○
M1	●	●	○	○
M2	●	○	○	●
M3	●	○	●	○
M4 все источники	●	●	●	●

Выделены версии, прошедшие все этапы проверки

Как обучали

Пары по одному участку генома: у одного человека — делеция, у другого — её нет. Запомнить координату бесполезно, модели приходится смотреть на прочтения конкретного человека.

50 человек

40 обучение · 5 настройка · 5 тест

12 272 пары участков

4 из 4 проверок на утечку ответа пройдены до обучения

Четыре уровня проверки

1

Контролируемый тест

5 отложенных людей, подготовленные пары

2

Развёрточное исследование

5 человек, реальные находки Manta; подбор порога на 95% чувствительности

3

Эталонный геном HG002

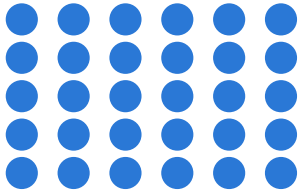
1 человек, открыт один раз



4

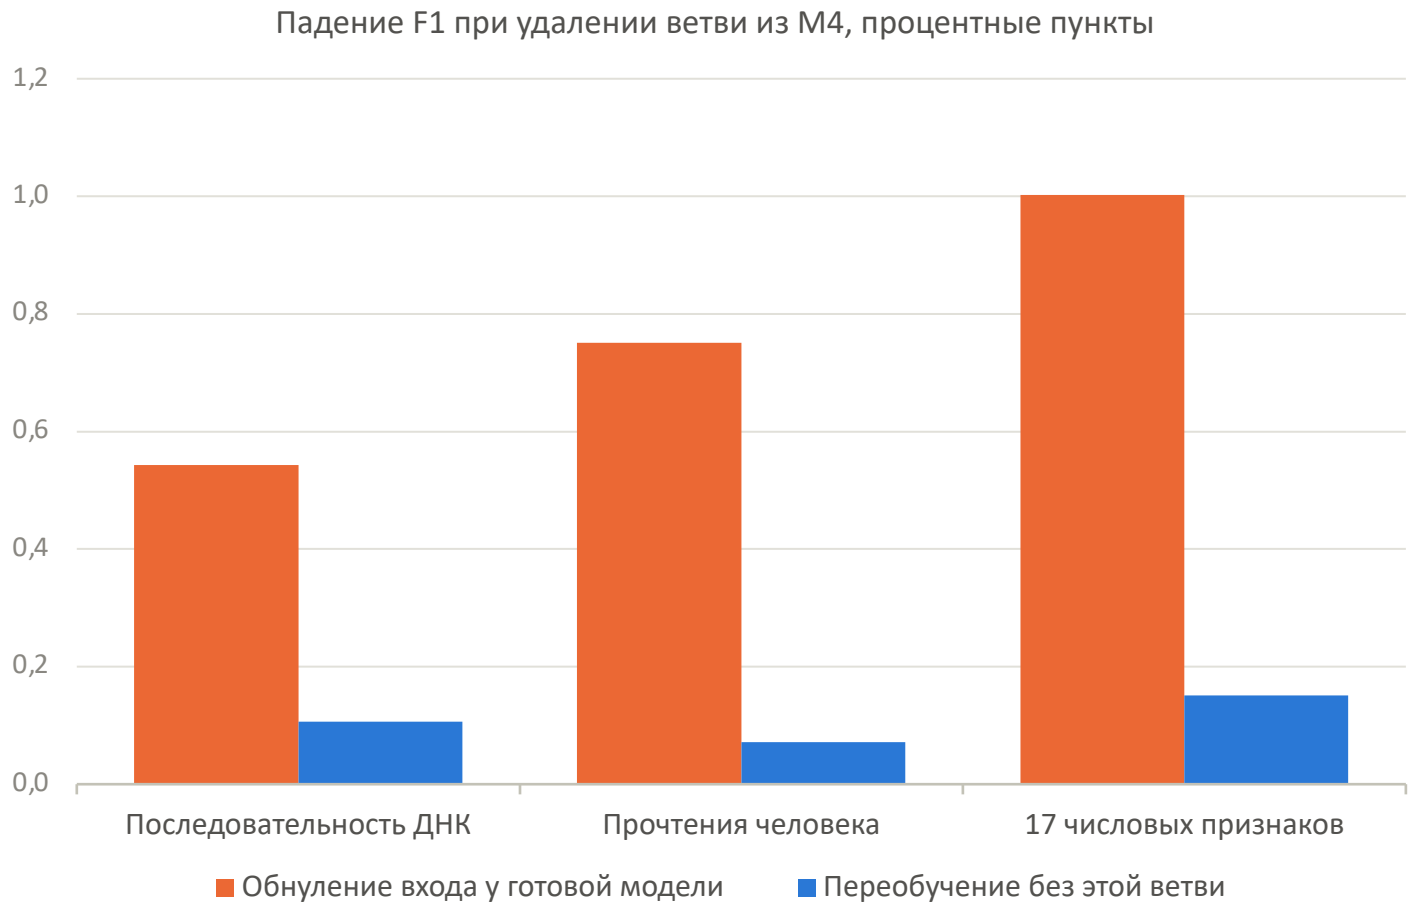
Новая группа

30 человек, по 6 из 5 групп происхождения; открыта один раз



До открытия данных фиксировались и хэшировались пороги, определения метрик, подгрупп и состав выборки. Менять правила задним числом было нельзя — как в клинических испытаниях.

Быстрая оценка вклада завышает его в 5–10 раз



Во сколько раз завышено

×5,1 Последовательность ДНК

×10,5 Прочтения человека

×6,6 17 числовых признаков

Честная оценка вклада — 0,07–0,15 п.п. F1 на ветвь: ветви в основном дублируют друг друга.

M4 не лучше M2: разница 0,11 п.п., интервал от −0,23 до +0,43.

Порог пришлось подбирать заново на реальных данных

4–7%

ложных находок отсеивалось с порогом, взятым с контролируемого теста: программа принимала почти всё

21–24%

после подбора порога поочерёдным исключением людей, при чувствительности около 95%

Различать программа не разучилась: площадь под ROC-кривой 0,75–0,76. Сдвинулась только граница отсечения — в реальном потоке почти 90% находок верные, а в подготовленных парах было поровну.

Порог переносился без сбоев: подобран на 4 людях, проверен на 5-м — все 45 проверок, худший случай чувствительности 0,9415.

На эталонном геноме HG002 версии разошлись

M0

94,9%

чувствительность

✗ **ниже цели на 0,1 п.п.**

отсев ложных: 27,4%

M2

95,5%

чувствительность

✓ **выше цели 95%**

отсев ложных: 25,0%

M4

93,3%

чувствительность

✗ **ниже цели на 1,7 п.п.**

отсев ложных: 32,2%

Напрашивался вывод: сложная M4 хуже переносится на нового человека — она на 2,2 п.п. ниже M2, хотя отсеивает больше всех. Мы записали это как гипотезу и проверили на 30 людях.

Эталон — GIAB v5.0q. Порог подобран на 5 людях развёрточного исследования и не перенастраивался.

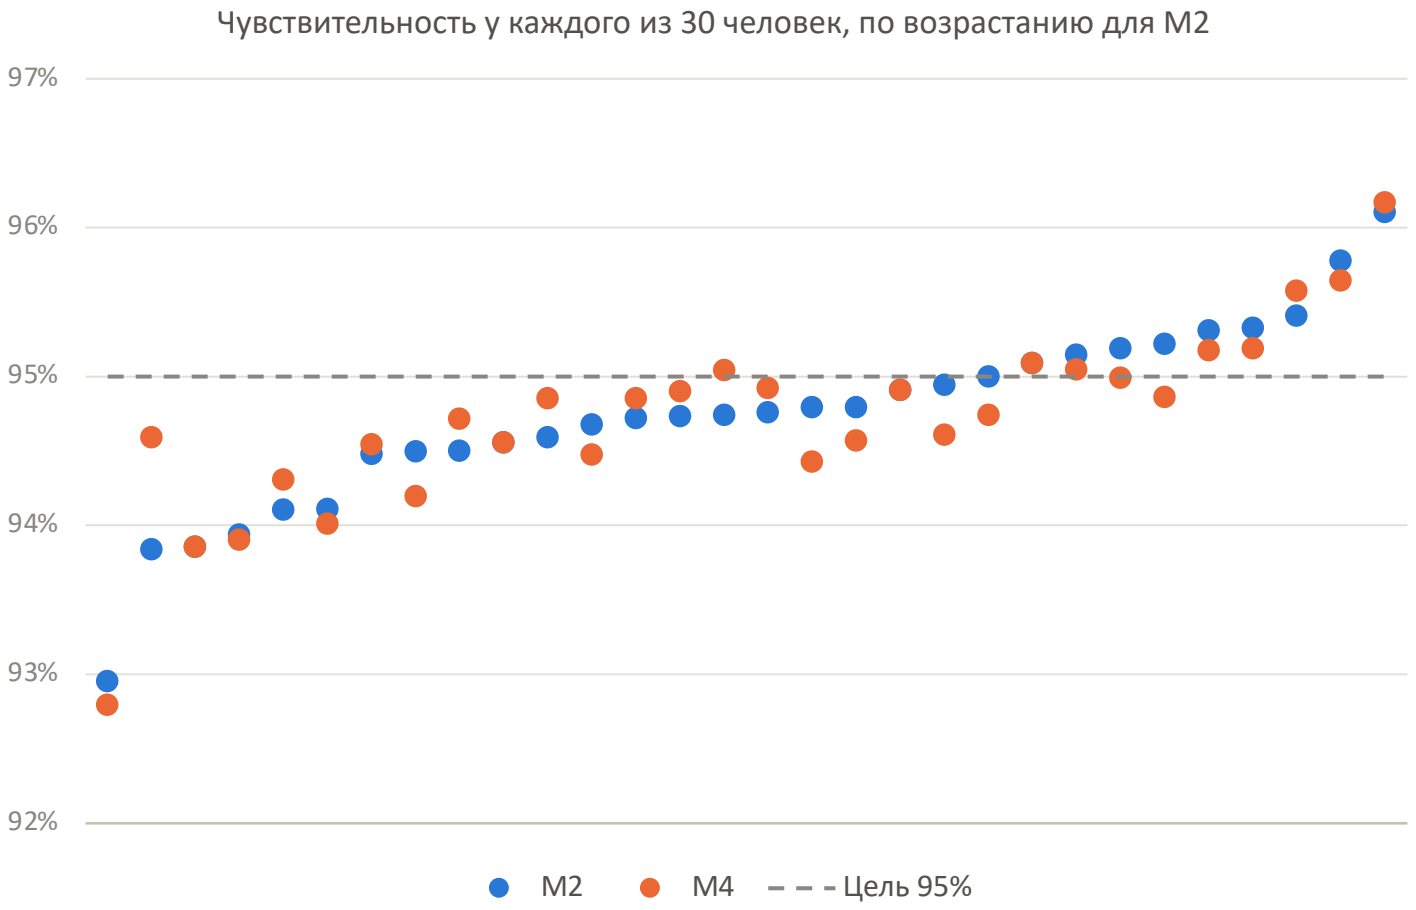
На 30 людях разница между версиями исчезла

в 35 раз

разница между M2 и M4 меньше обычного разброса между людьми

Разница M2 − M4	**0,000176**
Разброс между людьми	**0,0062**

Разброс — стандартное отклонение чувствительности M4 по 30 людям

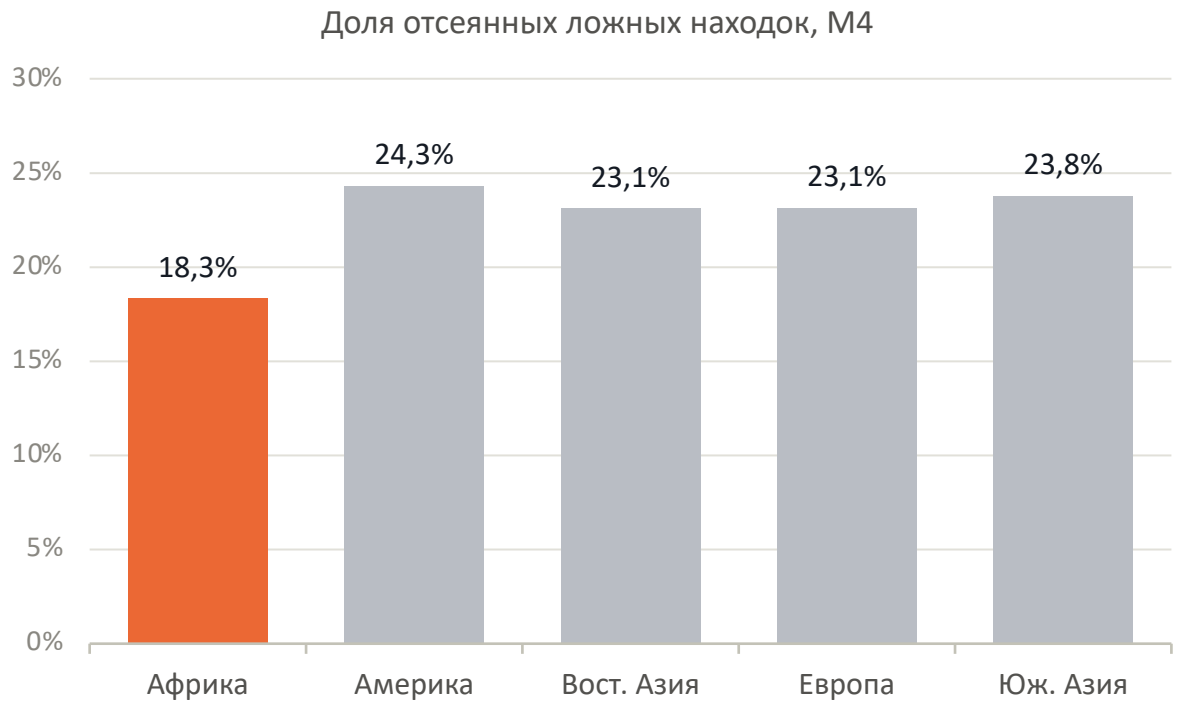


Цель 95% не достигнута, отсев хуже у одной группы

Ни одна версия не достигла 95%

M0	**94,53%**	чувствительность
M2	**94,73%**	чувствительность
M4	**94,71%**	чувствительность

Недобор одинаковый у всех: разброс между людьми около 0,6 п.п., все 30 человек — от 92,8% до 96,2%. После промаха порог не перенастраивали.



Находить делеции хуже не стала: чувствительность 94,2%–94,9% во всех группах. Вероятная причина — справочник эталонных ответов: по африканским популяциям в нём меньше данных. Причина не доказана.

ИТОГ СТАТЬИ 1

Проверки на одном геноме недостаточно — даже безупречно проведённой

Качество

Цель 95% не достигнута ни одной версией; недобор одинаковый у всех 30 человек

Обобщаемость

Различие M2 и M4 на HG002 не воспроизвелось на 30 людях

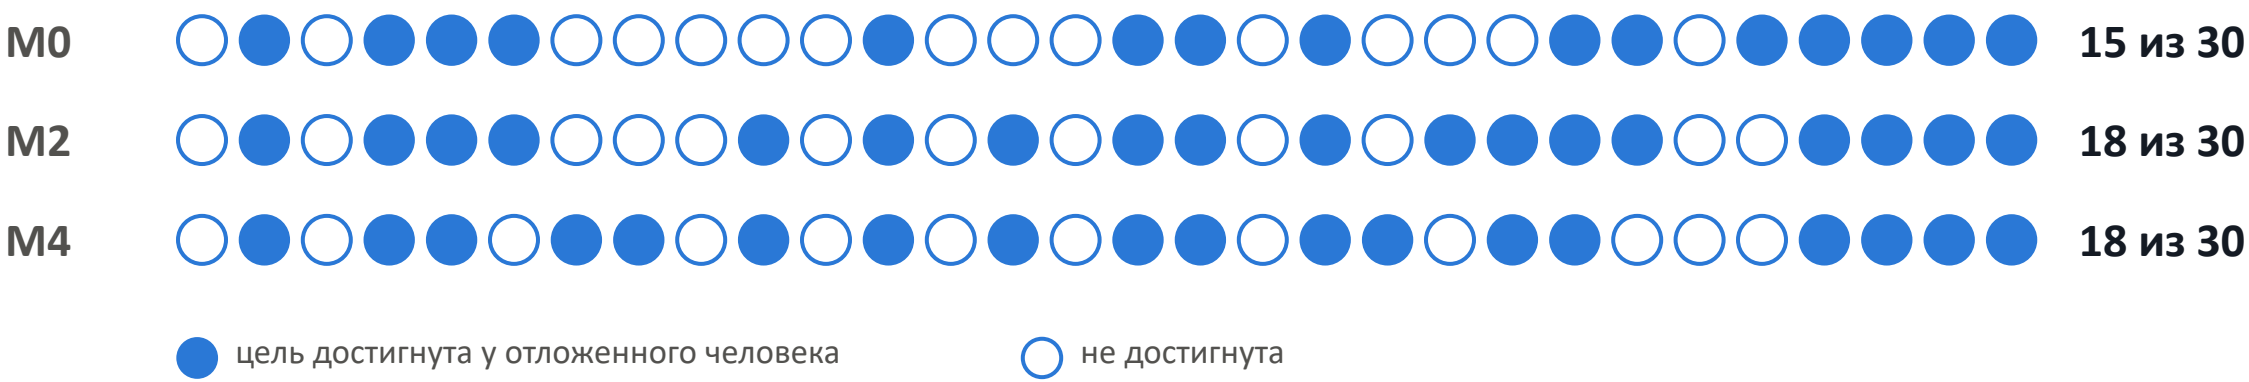
Методика оценки

Оба дешёвых способа — один геном и обнуление входа — дали завышенный эффект

Статья готова к подаче: английская версия и полная русская версия с PDF

Вторая статья: порог с гарантией

Старая процедура подбирает порог так, чтобы в среднем чувствительность была 95%. Держит ли она цель у нового человека? Проверка на всех 30: порог подобран на 29, результат — у 30-го.



Предлагаемая замена — конформный контроль риска (conformal risk control; Angelopoulos и др., ICLR 2024). Порог выбирается так, чтобы средняя доля пропущенных делеций у нового человека гарантированно не превышала заданную. Гарантия не зависит от вида распределения данных, но действует в среднем по новым людям, а не для каждого человека.

Для гарантии 95% нужно не меньше 19 человек

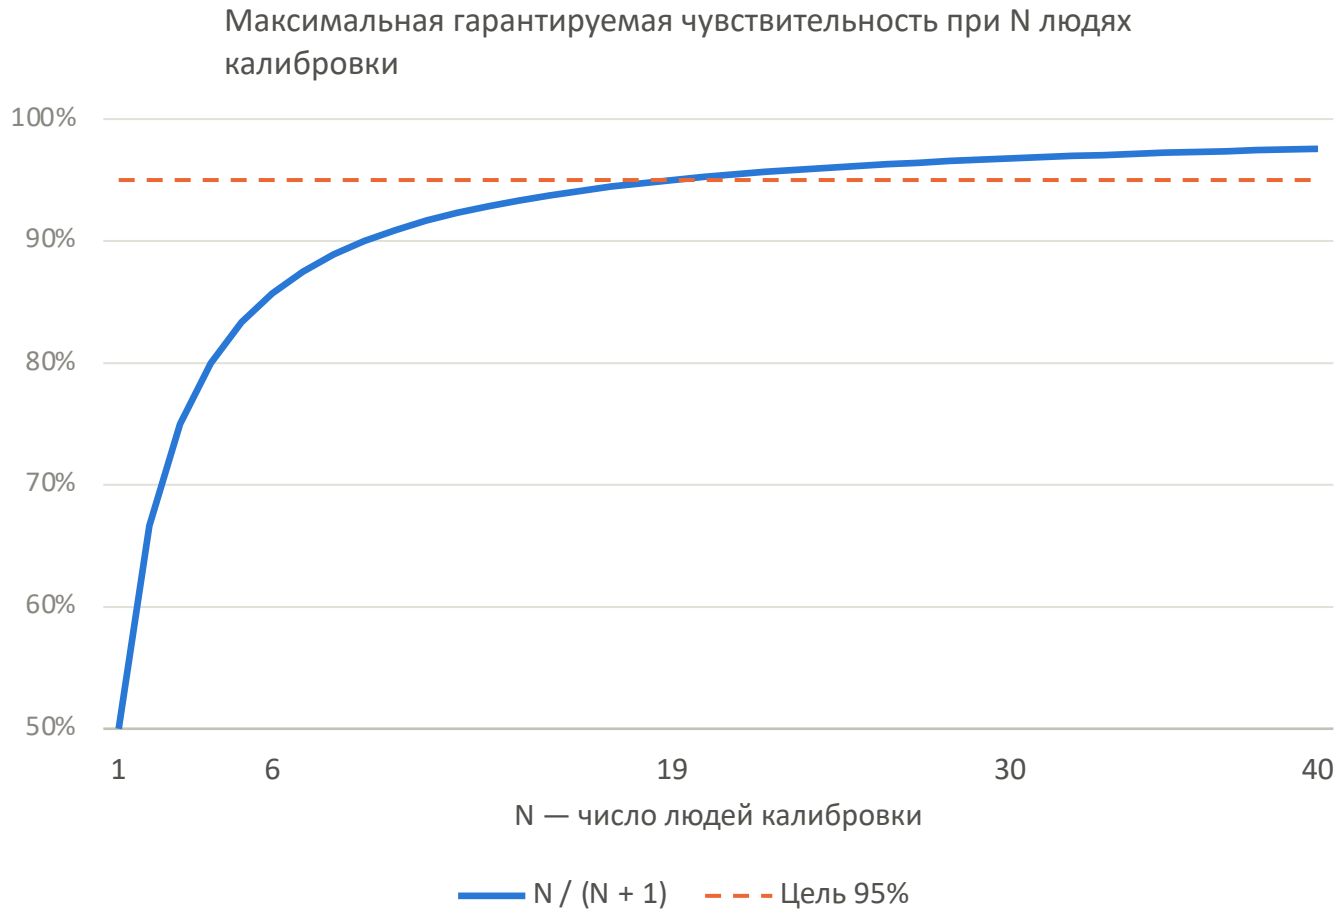
Максимальная гарантируемая чувствительность

$$\frac{N}{N+1}$$

N — число людей, на которых подбирают порог

N = 6	**до 85,7%**	одна группа происхождения
N = 19	**до 95,0%**	минимум для цели 95%
N = 30	**до 96,8%**	вся группа

Следует из условия теоремы (Cohen и др., ISIT 2024). Граница подтверждена перебором порогов на данных: при N = 5 цель 0,833 достижима, 0,834 — нет.



Калибровка по группам проигрывает общей

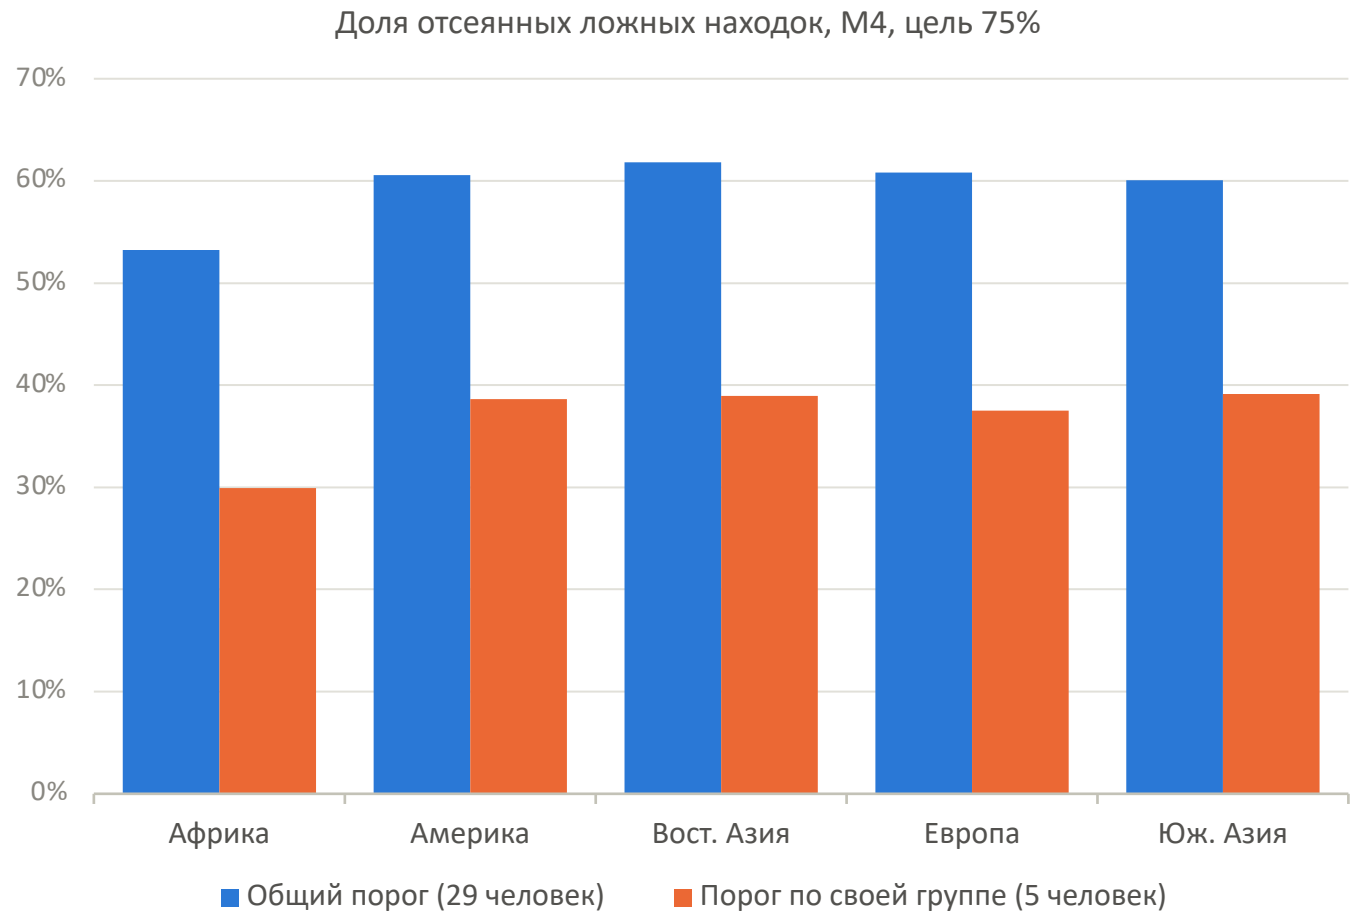
15 из 15

сочетаний «группа × версия» при цели 95%: на 6 людях гарантия невозможна, процедура отказывается выдавать порог

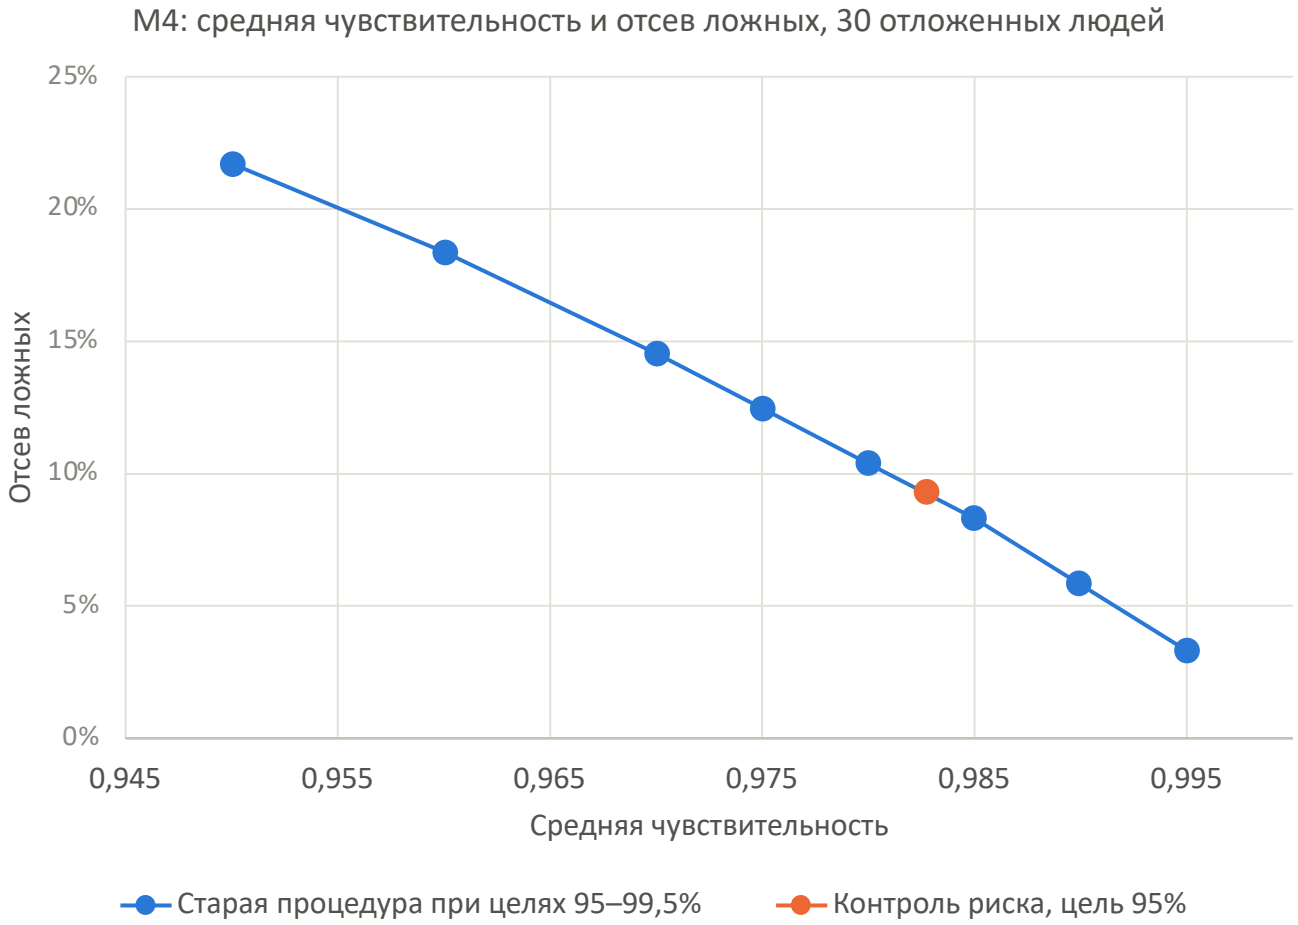
20–25 п.п.

меньше отсев ложных при пороге по своей группе, чем при общем (цель 75%, те же отложенные люди), во всех 5 группах и у всех 3 версий — без выигрыша в надёжности

Штраф за малую выборку 1/(N + 1): при N = 5 — 1/6, при N = 29 — 1/30



Проверка на честность: при равной надёжности



Обе держат цель у 30 из 30
старая, цель 97%: отсев **14,5%**
контроль риска, цель 95%: отсев **9,3%**
Лежит на той же кривой — не эффективнее

0,98276

эффективная чувствительность по формуле
1 − [α(N+1) − B] / N
измерено: **0,98276**
67% бюджета ошибки уходит на поправку за размер выборки

Ценность метода — надёжная точка сама собой, без подгонки по отложенным данным

Что даёт вторая статья и где её пределы

Что получено

1. Формула рабочей точки $1 - [\alpha(N+1) - B] / N$ — совпала с измерением до пятого знака
2. Граница $N / (N + 1)$: при 6 людях на группу гарантия 95% невозможна
3. Контроль при равной надёжности: без него сравнение с эвристикой некорректно

Ограничения

1. Группа из 30 человек использовалась многократно, без предрегистрации — в статье это будет сказано прямо
2. Гарантия действует в среднем по новым людям, а не для каждого человека
3. Метод не новый: контроль риска уже применяли в геномике (классификатор лейкозов ALLCoP). Новое — поведение при малых N

Статус: вычисления выполнены, пишется текст статьи

ПЛАНЫ

Дальше: генотип и доза вместо «есть / нет»

1

Генотип

Различать одну и две копии делеции (0/1 и 1/1). Метки уже есть в данных PanGenie.

2

Опора на родителей

Сверка с генотипами родителей: семья HG002–HG004 в GIAB, 602 семьи в 1000 Genomes.

3

Доза у картофеля

4 копии каждой хромосомы: доза делеции от 0 до 4, проверка по расщеплению у потомков; эталон — сборки сортов Otava, Altus, Désirée.

Уже есть у других: PSVGT (препринт, 2026) и Varigraph (Molecular Plant, 2025) определяют дозу у полиплоидов — это статистические методы, родителей они не используют.

Главный открытый вопрос: есть ли доступ к данным картофеля с родителями и потомками.

Итоги

1. Одного генома недостаточно: вывод, сделанный на HG002, не воспроизвёлся на 30 людях

2. Порог с гарантией возможен, но при реальных размерах выборки поправка на её размер определяет рабочую точку

3. Статья 1 готова к подаче; по статье 2 результаты получены, пишется текст

Спасибо за внимание

